

2. domača naloga: Rudarjenje podatkov

Rudarjenje podatkov je sistematično iskanje informacij v veliki količini podatkov. Pri tem želimo z uporabo polavtomatskih ali avtomatskih postopkov zgraditi modele, ki kar najbolj povezujejo podatke med seboj. Z zgrajenimi modeli lahko iz znanih podatkov ocenimo vrednosti neznanih podatkov, podatke uvrščamo v razrede, napovedujemo prihodnje obnašanje in podobno. Mnogi modeli podatkovnega rudarjenja se pri iskanju povezav med podatki pomagajo z entropijo. Model podatkov bomo z uporabo entropije zgradili tudi sami. V praksi model gradimo iz podatkov v učni množici, njegovo uspešnost pa preverjamo na podatkih iz testne množice, ki jih nismo uporabili med gradnjo modela. Da postopek poenostavimo, bomo v tej nalogi uspešnost modela preverjali kar na učni množici.

Podatki


Podatki v učni množici so predstavljeni z množico zapisov. Vsak zapis vključuje vrednosti N vhodnih diskretnih značilk ali atributov, $A_1, A_2, \dots, A_N$, iz katerih želimo kar najbolj enostavno določiti razred $R \in \{r_1, \dots, r_n\}$ zapisa. Pri tem značilka A_z zavzame eno od n_z vrednosti, $A_z \in \{a_{z1}, \dots, a_{zn_z}\}$. Podatki v tabeli 1 prikazujejo vpliv vremenskih dejavnikov (značilk) na odločitev za kolesarjenje (razred). Vsaka značilka lahko zavzame eno od dveh vrednosti: Nebo $\in \{j(\text{asno}), o(\text{blatno})\}$, Temp(eratura) $\in \{t(\text{toplo}), h(\text{ladno})\}$, Veter $\in \{v(\text{etrovno}), m(\text{irno})\}$, zapise želimo uvrščati v dva razreda Kolo $\in \{d(a), n(e)\}$.

Tabela 1: Vpliv vremenskih podatkov na kolesarjenje.

Nebo	j	j	j	j	j	j	o	o	o	o
Temp	h	h	t	h	h	t	t	t	t	t
Veter	v	v	v	m	m	m	v	v	m	m
Kolo	d	n	d	d	d	d	n	n	d	n

Gradnja drevesa

V nalogi bomo zgradili poenostavljeno odločitveno drevo [1], namenjeno uvrščanju podatkov v naprej določene razrede. Odločitveno drevo bomo gradili po korakih. Najprej bomo med vsemi vhodnimi značilkami izbrali tisto, ki najbolj loči razrede med seboj. Zapise ločimo na podlagi vrednosti izbrane značilke, kot prikazuje slika 1. Najbolj všečna je leva razdelitev, saj so v listih večinoma prisotni zapisi, ki sodijo v isti razred. Ta razdelitev je najbolj določena in ima zato najmanjšo entropijo. Postopek lahko v naslednjem koraku ponovimo na listih. Postopek izbiranja formalizirajmo. Vzemimo, da smo v prvem koraku izbrali značilko A_1^* s pripadajočim številom različnih vrednosti n_1^* . Če z delitvijo še nismo zadovoljni, v drugem koraku že izbrani značilki dodamo še eno. Drugo značilko A_2^* spet izberemo tako, da imajo listi, ki jih oblikujemo s parom značilk $A_1^*A_2^*$, čim več zapisov, ki pripadajo istemu razredu. Po $k-1$ korakih ima odločitveno drevo $\prod_{i=1}^{k-1} n_i^*$ listov, ki jih označimo z vrednostmi izbranih značilk $(A_1^*, A_2^*, \dots, A_{k-1}^*)$.



Slika 1: Izbiranje značilke, prvi korak.

Vzemimo, da izbrani zapis pripada razredu $r_i \in R$ z verjetnostjo $p(r_i)$. Potem lahko nedoločenost razreda zapišemo kot

$$H(R) = - \sum_{i=1}^n p(r_i) \log_2 p(r_i) \quad . \quad (1)$$

V vsakem koraku gradnje drevesa želimo z delitvijo po izbranih značilkah nedoločenost zmanjšati. V k -tem koraku značilko izberemo iz nabora še neuporabljenih značilk $A_z \in \{A_1, \dots, A_N\}$, $A_z \notin \{A_1^*, \dots, A_{k-1}^*\}$. Za vsako značilko A_z v drevesu iz prejšnjega koraka liste spremenimo v notranja vozlišča s po n_z novimi listi. Dobimo drevo z $L_z^k = n_z \prod_{i=1}^{k-1} n_i^*$ listi.

Glede na vrednosti značilk $(A_1^*, \dots, A_{k-1}^*, A_z)$, vse zapise razporedimo v liste z oznakami $l_{zj}^k \in \{l_{z1}^k, \dots, l_{zL_z^k}^k\}$. Za značilko A_z ločeno izračunamo nedoločenost razreda za vsakega od listov,

$$H(R|l_{zj}^k) = - \sum_{i=1}^n p(r_i|l_{zj}^k) \log_2 p(r_i|l_{zj}^k) \quad , \quad (2)$$

pri čemer je $p(r_i|l_{zj}^k)$ delež zapisov v listu l_{zj}^k , ki pripada razredu r_i . Nedoločenosti se po listih razlikujejo, zato za vrednotenje značilk uporabimo njihovo uteženo povprečje,

$$H(R|(A_1^*, \dots, A_{k-1}^*, A_z)) = \sum_{j=1}^{L_z^k} p(l_{zj}^k) H(R|l_{zj}^k) \quad , \quad (3)$$

kjer je $p(l_{zj}^k)$ delež vseh zapisov, ki so razvrščeni v list l_{zj}^k . Nazadnje med vsemi značilkami izberemo tisto, ki ima najmanjšo vrednost uteženega povprečja,

$$A_k^* = \arg \min_{A_z} H(R|(A_1^*, \dots, A_{k-1}^*, A_z)) \quad . \quad (4)$$

Ko v koraku K zaključimo z gradnjo drevesa, vsakemu listu priredimo razred iz R , v katerega sodi največ zapisov v listu.


Primer: prvi korak

Za zapise iz tabele 1 zgradimo odločitveno drevo. V razred d sodi šest zapisov, v razred n pa štirje, tako je nedoločenost $H(\text{Kolo}) = H(6/10, 4/10) = 0,971$ bit. Zapise poskusimo razdeliti glede na vse tri značilke. Delitev po značilki Nebo nam da dva lista, (j) in (o) . Kot vidimo na sliki 1, dobimo v listu (j) pet zapisov iz razreda d in en zapis iz razreda n , kar da nedoločenost lista $H(\text{Kolo}|\{j\}) = H(5/6, 1/6) = 0,650$ bit. Na enak način izračunamo nedoločenost v listu (o) , $H(\text{Kolo}|\{o\}) = H(1/4, 3/4) = 0,811$ bit. V listu (j) imamo skupaj šest zapisov, $p(\{j\}) = 0,6$, v listu (o) pa štiri, $p(\{o\}) = 0,4$. Povprečna nedoločenost je tako $H(\text{Kolo}|\{\text{Nebo}\}) = p(\{j\})H(\text{Kolo}|\{j\}) + p(\{o\})H(\text{Kolo}|\{o\}) = 0,715$ bit.

Na enak način izračunamo še povprečne nedoločenosti za značilki Temp in Veter. Vidimo, da je povprečna entropija najmanjša za Nebo, zato za najpomembnejšo značilko izberemo $A_1^* = \text{Nebo}$. V listu (j) je največ zapisov iz razreda d , zato listu priredimo razred d (na sliki odebeljen). Iz istega razloga listu (o) priredimo razred n .

Primer: drugi korak

Potem, ko smo v prvem koraku izbrali značilko $A_1^* = \text{Nebo}$, lahko v drugem koraku izbiramo samo še med značilkami Temp in Veter. Zapise iz listov v prvem koraku razdelimo še glede na preostali značilki. Za značilki Temp in Veter dobimo razporeditvi, prikazani na sliki 2.



Slika 2: Izbiranje značilk, drugi korak.

V desnem drevesu smo zapise uvrstili v štiri liste, katerih imena so določena iz vrednosti značilk Nebo in Veter: (j, v) , (j, m) , (o, v) in (o, m) . Število zapisov v posameznem listu določa verjetnost za list: $p(\{j, v\}) = p(\{j, m\}) = 0,3$, $p(\{o, v\}) = p(\{o, m\}) = 0,2$. V vsakem listu iz števila zapisov, ki sodijo v razred d , oziroma v razred n , določimo še entropijo $H(\{j, v\}) = H(2/3, 1/3) = 0,918$ bit, $H(\{j, m\}) = H(3/3, 0/3) = 0$ bit, $H(\{o, v\}) = H(0/2, 2/2) = 0$ bit in $H(\{o, m\}) = H(1/2, 1/2) = 1$ bit. Uteženo povprečje entropij vseh štirih listov nam da

$H(\text{Kolo}|\text{(Nebo, Veter)}) = 0,475$ bit. Na enak način postopamo tudi za značilko Temp. V drugem koraku izberemo značilko $A_2^* = \text{Veter}$, s katero dobimo manjšo entropijo.

Listom priredimo razrede glede na večinsko zastopanost zapisov. Pri listu (o, m) izberemo katerikoli razred, saj sta enako zastopana.

Uporaba modela

Zdaj, ko je odločitveno drevo zgrajeno, lahko za poljubne zapise preverimo, kako dobro model razvršča. Glede na vrednosti značilk se sprehodimo po odločitvenem drevesu in zapisu določimo razred, ki smo ga prej priredili listu. Uspešnost modela ovrednotimo z deležem pravilno uvrščenih zapisov ali točnostjo (angl. accuracy).

Primer: uvrščanje z značilko Nebo

Najprej uporabimo rešitev, ki smo jo dobili v prvem koraku. V tabeli 2 iz značilke Nebo zapisom določimo pričakovani razred. Zapisani so v vrstici z oznako Kolo-N1. Zapisi, pri katerih ima značilka Nebo vrednost j , pripadajo vozlišču (j) , zato jim določimo razred d . Zapisom z vrednostmi o pa iz istega razloga določimo razred n . Vidimo, da smo z

Tabela 2: Vpliv vremenskih podatkov na kolesarjenje.

Nebo	j	j	j	j	j	j	o	o	o	o
Kolo-N1	d	d	d	d	d	d	n	n	n	n
Kolo	d	n	d	d	d	d	n	n	d	n

odločitvenim drevesom pravilno uvrstili osem zapisov, dva pa narobe. Zaključimo, da je točnost odločitvenega drevesa enaka

$$\eta = \frac{8}{10} = 0,8 \quad . \quad (5)$$

Primer: uvrščanje z značilkama Nebo in Veter

Postopamo podobno kot prej, le da zdaj razred določamo glede na vrednost značilk Nebo in Veter. Uvrstitve v razrede prikazuje tabela 3 v vrstici z oznako Kolo-N2. Tudi v tem

Tabela 3: Vpliv vremenskih podatkov na kolesarjenje.

Nebo	j	j	j	j	j	j	o	o	o	o
Veter	v	v	v	m	m	m	v	v	m	m
Kolo-N2	d	d	d	d	d	d	n	n	d	d
Kolo	d	n	d	d	d	d	n	n	d	n

primeru je točnost

$$\eta = \frac{8}{10} = 0,8 \quad . \quad (6)$$

Ta model je zagotovo boljši od prejšnjega, saj je povprečna nedoločenost bistveno manjša. Na žalost je nabor zapisov takšen, da se kvaliteta modela ne odraža tudi v točnosti.

Osnovna naloga

V datoteki `naloga2.py` v jeziku Python napišite funkcijo z imenom `naloga2`. Vhodni argumenti funkcije so

- slovar značilke s pripadajočimi seznamami vrednosti (`znacilke`),
- seznam razredov (`razredi`) in
- število korakov (`koraki`).

Funkcija vrne terko, ki vsebuje:

- povprečno entropijo $H(R|A_K^*)$ za zgornji nabor (`entropija`) in
- točnost odločitvenega drevesa (`točnost`),

Prototip funkcije:

```
def naloga2(znacilke: dict, razredi: list, koraki: int) -> tuple:

    entropija = float('inf')
    točnost = float('inf')

    # Napisite svojo kodo tukaj

    return (entropija, točnost)
```

Testni primeri

Na učilnici se nahajajo trije testni primeri podatkov, za katere imate podane tudi rešitve: povprečno informacijo `entropija` (v bitih) in točnost `točnost`. Podatki so podani v obliki datotek `.json`. Priloženo imate tudi funkcijo `test_naloga2`, ki jo lahko uporabite za preverjanje pravilnosti rezultatov. Pri testiranju vaših funkcij upoštevajte naslednje omejitve:

- rezultat je pravilen, če se od danega razlikuje za manj kot 10^{-4} ,
- izvajanje funkcije je časovno omejeno na 30 sekund.
- Vaš program lahko uporablja samo tiste pakete, ki so del standardne knjižnice Python 3.12 (<https://docs.python.org/3.11/library/>) in paketa `numpy`. Na sistemu za preverjanje vaših rešitev drugi paketi niso nameščeni.

Točkovanje

Pri vsaki nalogi dobite pol točke za pravilen izračun entropije in pol točke za pravilen izračun točnosti.

Dodatna naloga – tekmovanje

V dodatni nalogi bomo pravilno sledili standardnim pristopom pri rudarjenju podatkov – odločitveno drevo bomo gradili na podlagi zapisov iz učne množice, njegovo uspešnost pa preverili na zapisih iz skrite testne množice. Zmagal bo model, ki bo dal najboljše rezultate na zapisih iz skrite testne množice.

Modelirali bomo obnašanje avtonomnega vozila, ki je opremljeno s 30 tipali. V podatkovni množici je več tisoč zapisov o stanju tipal (značilke) in potrebnih akcij (razredi). Za razliko od podatkovnih množic iz prejšnje naloge, so tokrat vrednosti značilk realne vrednosti. Za gradnjo robustnega odločitvenega drevesa priporočamo, da nabor možnih vrednosti značilk zmanjšate. Značilke uvrstite v manjše število intervalov (diskretizirajte), nato pa pri modeliranju uporabite oznako intervala, v katerega pade vrednost. Število diskretnih vrednosti in način diskretizacije določite sami. Vrednosti v zapisih iz testne množice so lahko tudi malce večje od največje ali manjše od najmanjše vrednosti v učni množici. Avtonomno vozilo pozna samo štiri akcije: vožnja naprej (N), zavijanje levo (L), zavijanje desno (D) in izogibanje oviri (O). Zapisi si sledijo kronološko, zato lahko za določanje akcije v časovnem koraku t uporabite tudi stanje tipal v prejšnjih korakih $t - 1, \dots, t - 10$.

Za gradnjo modela lahko uporabite vse podatke iz učne množice. Pri tem je priporočljivo, da večji delež zapisov uporabite za gradnjo modela, ostale (vsaj 15 %) pa za njegovo preverjanje (validacijo). Z vrednotenjem modela na zapisih za preverjanje lahko pravočasno zaznate, da se je model preveč prilagodil na zapise, uporabljene pri gradnji. Na neznanih podatkih se bo model, ki je dal najboljše rezultate na zapisih za preverjanje, večinoma obnašal bolje od modela, ki se zelo dobro prilagaja zapisom, uporabljenim za gradnjo.

Izhajajte iz modela, ki ste ga zgradili v osnovni nalogi. Izboljšani model mora ostati odločitveno drevo, ki uporablja mero na osnovi entropije. V osnovni nalogi smo v k -tem koraku v vseh vejah iz koraka $k - 1$ zapise ločevali po isti značilki. Model bo verjetno deloval bolje, če boste za vsako vejo posebej poiskali značilko, ki najboljše loči zapise.

Uspešnost zgrajenega modela bomo ovrednotili na zapisih iz skrite testne množice. Zmagal bo model, ki bo največ zapisov razvrstil v prave razrede. Napovedi razredov za prvih 10 zapisov iz skrite množice pri vrednotenju ne bomo upoštevali.

Podatkovna množica je shranjena v datoteki `av.json`, ki tokrat vključuje slovar značilk s pripadajočimi seznamami vrednosti (`znacilke`) in seznam razredov (`razredi`). V datoteki `nalogat.py` v jeziku Python napišite funkcijo z imenom `nalogat`. Vhodni argumenti funkcije so

- slovar značilk iz učne množice s pripadajočimi seznamami vrednosti (`znacilkeUcna`),
- seznam razredov iz učne množice (`razrediUcna`) in
- slovar značilk iz testne množice s pripadajočimi seznamami vrednosti (`znacilkeTestna`).

Funkcija vrne seznam napovedanih razredov za testno množico (`razrediTestna`). Dolžina seznama mora biti enaka dolžinam seznamov v `znacilkeTestna`, pri tem mora i -ta vrednost v seznamu `razrediTestna` ustrezati i -temu zapisu v `znacilkeTestna`. Za prvih 10 zapisov so vrednosti v seznamu `razrediTestna` lahko `NaN`.

Prototip funkcije:

```
def naloga2tekma(znacilkeUcna: dict,
                 razrediUcna: list,
                 znacilkeTestna: dict) -> list:

    # Ker vemo, da sta v datoteki av.json
    # znacilkeTestna in razrediTestna enaki zadnjim zapisom
    # znacilkeUcna in razrediUcna, imamo trivalno resitev.
    # Pri vrednotenju vasih modelov, to ne bo res.
    records = len(znacilkeTestna[list(znacilkeTestna.keys())[0]])
    razrediTestna = list('N'*records)

    # Napisite svojo kodo tukaj

    return razrediTestna
```

Priloženo imate datoteko `test_naloga2tekma.py` s funkcijo `test_naloga2tekma`, ki iz datoteke prebere podatkovno množico in pokliče funkcijo `naloga2tekma` z ustreznimi argumenti. Značilke in razredi za testno množico so enaki zadnjim 100 zapisom v učni množici. Prototip funkcije vrne kar seznam z ustreznim številom elementov, pri čemer so vsi elementi enaki 'N'.

Izvajanje funkcije je časovno omejeno na 120 sekund. Vaš program lahko uporablja samo tiste pakete, ki so del standardne knjižnice Python 3.12 (<https://docs.python.org/3.11/library/>) in paketa `numpy`. Na sistemu za preverjanje vaših rešitev drugi paketi niso nameščeni.

Točkovanje

Za vsak zapis (izvzetih je prvih 10) bomo razred, ki ga bo model predlagal iz značilk, primerjali s pravim razredom v zapisu. Več pravilnih napovedi bo vrnil model, bolj natančen bo in zato bo tudi bolje ocenjen. Dodatne točke h končni oceni bomo dodelili po naslednjem kriteriju:

1. mesto: +10 %,
2. mesto: +8 %,
3. mesto: +5 %.

Ostali udeleženci tekmovanja dobite +3 % h končni oceni pri predmetu. Upoštevali bomo samo tiste oddane naloge, ki bodo pravilno napovedale razred za vsaj 50 % zapisov iz testne množice.

Namigi**Delajte sami**

Pri preverjanju nalog uporabljamo tudi sistem za zaznavanje plagiatorstva. Verjemite, da

prepisovanje težko zakrijete.

Uporabne funkcije in razredi

`zip`, `sum`, `math.log2`, `collections.Counter`

Literatura

[1] D.G. Luenberger: Information Science, Princeton University, str. 43-44, 2006.